


Logistic Regression 逻辑回归

sigmoid 函数

相较于线性回归的因变量 y 为连续值，逻辑回归的因变量则是一个 0/1 的二分类值，这就需要我们建立一种映射将原先的实值转化为 0/1 值。这时候就要请出我们熟悉的 sigmoid 函数了：

$$y = \frac{1}{1 + e^{-z}}$$

其函数图形如下：



该函数具有很好的数学性质，既可以用于预测类别，并且任意阶可微，因此可用于求解最优解。将函数带进去，可得 LR 模型为

$$y = \frac{1}{1 + e^{-(w^T x + b)}}$$

sigmoid 函数还有一个很好的特性就是其求导计算等于下式，这给我们后续求交叉熵损失的梯度时提供了很大便利。sigmoid 函数求导：

$$y' = y \times (1 - y)$$

其实，LR 模型就是在拟合 $z = w^T x + b$ 这条直线，使得这条直线尽可能地将原始数据中的两个类别正确的划分开。

损失函数

LR 解决二分类问题中，交叉熵损失函数为如下形式

$$L = -[y \log \hat{y} + (1 - y) \log(1 - \hat{y})]$$

这个函数通常又称为对数损失 **logloss**，这里的对数底为自然对数 e ，其中真实值 y 是有 0/1 两种情况，而推测值 \hat{y} 由于借助对数几率函数，其输出是介于 0~1 之间连续概率值。因此损失函数可以转换为分段函数

$$L = \begin{cases} -\log(\hat{y}), & y = 1 \\ -\log(1 - \hat{y}), & y = 0 \end{cases}$$

优化求解

确定损失函数后，要不断优化模型。LR 的学习任务转化为数学的优化形式为

$$(w^*, b^*) = \arg \min_{w, b} L(w, b)$$

是一个关于 **w** 和 **b** 的函数。同样，采用梯度下降法进行求解，过程需要链式求导法则

$$\frac{\partial L}{\partial w} = \frac{1}{m} x(\hat{y} - y)$$

$$\frac{\partial L}{\partial b} = \frac{1}{m} \sum_{i=1}^m (\hat{y} - y)$$

$$w \leftarrow w - \alpha \frac{\partial L}{\partial w}$$

$$b \leftarrow b - \alpha \frac{\partial L}{\partial b}$$